

BÁO CÁO MÔN HỌC

Tấn công và phòng thủ đối nghịch trên bộ phân loại hình ảnh

FGSM attack · Adversarial training · CIFAR-10



Nhóm 12 · IT5416 · GVHD: TS. Nguyễn Đức Anh

Vấn đề nghiên cứu

Mô hình học sâu có thể đạt accuracy cao trên dữ liệu sạch, nhưng vẫn bị đánh lừa bởi nhiễu rất nhỏ mà mắt người khó nhận biết.

- Adversarial examples làm thay đổi dự đoán dù ảnh gần như không đổi về mặt thị giác.
- Rủi ro ảnh hưởng trực tiếp tới các hệ thống AI cần độ tin cậy cao.
- Cần đánh giá robustness, không chỉ đánh giá accuracy trên dữ liệu sạch.

Mục tiêu và quy trình

1

Fine-tune baseline

MobileNetV2, ResNet18,
EfficientNet-B0 trên CIFAR-10

2

Tấn công FGSM

Sinh ảnh đối nghịch với $\epsilon = 0, 2/255, 4/255, 8/255$

3

Huấn luyện đối nghịch

Kết hợp ảnh sạch và ảnh FGSM trong quá trình huấn luyện

4

So sánh kết quả

Đánh giá trade-off giữa clean accuracy và adversarial robustness

Dữ liệu CIFAR-10

60.000

ảnh màu 32×32

10

lớp đối tượng cân bằng

50k / 10k

train / test

224×224

resize để dùng pretrained
CNN

- Phù hợp để triển khai nhanh nhiều mức nhiễu và so sánh giữa mô hình.
- Độ phân giải thấp khiến tác động của nhiễu đối nghịch lên đặc trưng mô hình dễ quan sát.
- Tiền xử lý cần nhất quán giữa huấn luyện, kiểm thử và sinh mẫu đối nghịch.

Ba mô hình baseline

MobileNetV2

3.5M tham số

Nhẹ, dùng depthwise separable convolution; phù hợp thiết bị tài nguyên thấp.

ResNet18

11.7M tham số

Residual connections giúp huấn luyện mạng sâu ổn định; baseline CNN phổ biến.

EfficientNet-B0

5.3M tham số

Compound scaling và MBConv; tối ưu giữa độ chính xác và chi phí tính toán.

Cơ sở toán học của baseline

Mỗi baseline học một hàm phân loại $f_{\theta}(x)$, biến ảnh đầu vào thành vector điểm số cho 10 lớp CIFAR-10.

Dự đoán nhãn

$$\hat{y} = \underset{k}{\operatorname{argmax}} \operatorname{softmax}(f_{\theta}(x))_k$$

Hàm mất mát

$$L_{\text{clean}}(\theta) = \text{CE}(f_{\theta}(x), y)$$

- MobileNetV2: depthwise separable convolution và inverted residual giúp giảm chi phí tính toán.
- ResNet18: residual block học $y = F(x, W) + x$, hỗ trợ truyền gradient ổn định.
- EfficientNet-B0: compound scaling cân bằng độ sâu, độ rộng và độ phân giải.

Tấn công FGSM

Fast Gradient Sign Method tạo nhiễu theo hướng làm tăng loss của mô hình đối với ảnh đầu vào.

- Một bước, chi phí thấp, dễ triển khai.
- ϵ điều khiển cường độ nhiễu.
- Sau khi thêm nhiễu, ảnh cần được clamp về miền giá trị hợp lệ.

Công thức toán học:

$$x_{adv} = x + \epsilon \cdot \text{sign}(\nabla_x J(\theta, x, y))$$

- Trong đó:
 - x_{adv} : Hình ảnh đối nghịch được tạo ra.
 - x : Hình ảnh gốc sạch.
 - ϵ (Epsilon): Hệ số nhiễu (thường rất nhỏ, ví dụ 0.01 hoặc 0.03).
 - $\nabla_x J$: Gradient của hàm mất mát đối với hình ảnh đầu vào.

Cơ sở toán học của phòng thủ

Adversarial training tối ưu mô hình trong trường hợp xấu nhất khi ảnh bị nhiễu trong miền cho phép.

$$\min_{\theta} E_{(x,y)} [\max_{\{ ||\delta||_{\infty} \leq \epsilon \}} CE(f_{\theta}(x + \delta), y)]$$

Sinh ảnh đối nghịch

$$x_{adv} = \text{clamp}(x + \epsilon * \text{sign}(\text{grad}_x \\ CE(f_{\theta}(x), y)), 0, 1)$$

Loss huấn luyện

$$L_{total} = 0.7 * CE(f_{\theta}(x), y) + 0.3 * \\ CE(f_{\theta}(x_{adv}), y)$$

Ý nghĩa: mô hình vẫn học trên ảnh sạch, đồng thời được ép ổn định hơn trước nhiễu FGSM.

Thiết lập thực nghiệm

- Dataset: CIFAR-10, ảnh resize về 224×224 để phù hợp kiến trúc pretrained.
- Baseline: fine-tune trên dữ liệu sạch, thay lớp phân loại cuối bằng 10 đầu ra.
- Attack: đánh giá trên các mức $\epsilon = 0, 2/255, 4/255, 8/255$.
- Defense: FGSM adversarial training, sau đó đánh giá lại với cùng tập test và cùng mức ϵ .

Ba baseline dùng cùng một bộ tham số huấn luyện; slide sau tóm tắt cấu hình lấy trực tiếp từ notebook.

Cấu hình huấn luyện dùng chung

Các tham số dưới đây được giữ giống nhau cho MobileNetV2, ResNet18 và EfficientNet-B0.

Optimizer

Adam

`optim.Adam(model.parameters(), lr=1e-4)`

Learning rate

1e-4

Không dùng scheduler trong notebook

Batch size

Train: 64 · Test: 1

Train shuffle=True, num_workers=2; test shuffle=False

Số epoch

5 + 5

5 epoch fine-tune clean, 5 epoch FGSM adversarial training


Normalization

Resize(224×224) + ToTensor(); không dùng Normalize(mean/std). FGSM clamp ảnh về [0,1].

Checkpoint

Lưu state_dict sau clean training và sau FGSM AT: *_clean.pth, *_fgsm_at.pth.


Baseline suy giảm mạnh dưới FGSM



Insight chính

- Accuracy sạch đều trên 93%.
- Chỉ cần $\epsilon = 2/255$, hiệu năng đã giảm rất sâu.
- Clean accuracy cao không đồng nghĩa với robustness cao.


Ví dụ ảnh bị phân loại sai



Các thay đổi ở mức pixel có thể rất nhỏ với người quan sát, nhưng đủ làm mô hình chuyển sang nhãn sai.

- Ảnh gốc vẫn giữ hình dạng tổng thể.
- Mô hình dựa vào đặc trưng nhạy cảm hơn mắt người.
- Đây là lý do cần đánh giá trên dữ liệu đối nghịch.

Adversarial training cải thiện robustness



Kết luận từ bảng

- Robust accuracy tăng rõ ở ϵ lớn.
- ResNet18 cân bằng nhất giữa clean và robust accuracy.
- EfficientNet-B0 cải thiện mạnh nhưng clean accuracy giảm sâu.

Phân tích kết quả

Thông điệp chính

- FGSM cho thấy mô hình nhạy với nhiễu có chủ đích.
- Adversarial training giúp ranh giới quyết định ổn định hơn.
- Có đánh đổi giữa accuracy sạch và độ bền vững đối nghịch.

Kết quả đáng chú ý

- ResNet18 đạt cân bằng tốt nhất giữa clean accuracy và robust accuracy.
- EfficientNet-B0 đạt robust accuracy cao sau FGSM AT, nhưng clean accuracy giảm mạnh.
- MobileNetV2 cải thiện rõ sau phòng thủ, phù hợp hướng mô hình nhẹ.

Kết luận và hướng phát triển

Kết luận

- Các mô hình pretrained đạt hiệu năng cao trên dữ liệu sạch.
- FGSM làm accuracy suy giảm mạnh, chứng minh điểm yếu về robustness.
- FGSM adversarial training cải thiện đáng kể khả năng chống chịu.

Hướng phát triển

- Thử attack mạnh hơn: PGD, BIM, C&W.
- Mở rộng sang dataset phức tạp hơn.
- Tối ưu epsilon, learning rate, epoch và chiến lược trộn dữ liệu.

Cảm ơn thầy/cô và các bạn đã lắng nghe

Nhóm 12 · IT5416

Q&A